


REGULACJA PREDYKCYJNA (MPC)

- Algorytmy regulacji predykcyjnej – **MPC (Model Predictive Control)**, powstały w latach siedemdziesiątych ub. wieku, następnie intensywnie rozwijane..
- Jedynie z tzw. **zaawansowanych technik regulacji (advanced control techniques)**, które odniosły olbrzymi sukces w aplikacjach praktycznych, wywierając dominujący wpływ na kierunek rozwoju przemysłowych układów regulacji i sterowania.
- MPC – technika **silnie oparta na modelu obiektu** (MPC także: *Model-based Predictive Control*), wymagająca znacznie większego nakładu obliczeń niż algorytmy PID, mogła się rozwinąć dzięki postępom techniki mikroprocesorowej.
- Kilka przyczyn **sukcesu algorytmów MPC**:
 - W sposób naturalny potrafią uwzględnić **ograniczenia sygnałów sterujących i wielkości wyjściowych**, decydujące często o jakości i bezpieczeństwie produkcji.
 - Generują aktualne sterowania bezpośrednio wykorzystując model procesu. Stąd w sposób naturalny można je stosować do **obiektów wielowymiarowych z silnymi interakcjami**, również przy nierównej liczbie wejść sterujących i wielkości regulowanych, do **obiektów o trudnej dynamice**.
 - Algorytmy, których **zasada działania jest zrozumiała**, stosunkowo łatwa do wyjaśnienia personelowi inżynierskiemu jak i operatorskiemu - aspekt bardzo istotny przy wprowadzaniu nowych technik do praktyki przemysłowej.

REGULACJA PREDYKCYJNA (MPC) 2

Typowa sytuacja, w której regulacja MPC zapewnia [wzrost efektywności ekonomicznej produkcji](#):



REGULACJA PREDYKCYJNA (MPC) 3

Trochę historii:

- **Model Predictive Heuristic Control** (MPHC) – Richalet i in. (1976, 1978) – zaimplementowany w komercyjnym pakiecie IDCOM (*Identification and Command*), znany później pod nazwą algorytm MAC (*Model Algorithmic Control*). Model liniowy obiektu w postaci skończonej odpowiedzi impulsowej (FIR – *Finite Impulse Response*).
- **Dynamic Matrix Control** (DMC) – firma Shell Oil (pierwsza połowa lat siedemdziesiątych ub. stulecia, opublikowany 1980, wraz z informacjami o udanych aplikacjach). Bardzo popularny w komercyjnych aplikacjach algorytmów regulacji MPC. Liniowy model obiektu w postaci odpowiedzi skokowych.
- **Generalized Predictive Control** (GPC) – Clarke i in. (1987, 1989). Model procesu w postaci transmitancji dyskretniej (równań różnicowych), pozwala na regulację predykcyjną również obiektów niestabilnych.
- **Algorytm MPC z równaniami stanu** (MPCS) – podejście najogólniejsze, też dla modeli nieliniowych, dla najszerszej klasy zakłóceń. Wymaga pomiaru lub estymacji stanu. Obecnie najpopularniejszy w pracach badawczych, występuje w nowoczesnych pakietach komercyjnych, szczególnie dla procesów nieliniowych.


W zakresie badań i zastosowań algorytmów MPC w ostatnich latach i obecnie, dominują problemy efektywności, uwzględniania nieliniowych modeli, stabilności, odporności na niepewność modelowania i estymacji zakłóceń.

REGULACJA PREDYKCYJNA (MPC) 4

W ofercie wszystkich znaczących producentów sprzętu i oprogramowania dla sterowania i regulacji obiektów przemysłowych znajdują się pakiety oprogramowania z algorytmami MPC (istnieją też firmy specjalizujące się w aplikacjach), **bardziej znane produkty**:

- **DMCplus** firmy **AspenTech**, sukcesor klasycznego algorytmu DMC (Cutler i Ramaker, 1979),
- **IDCOM-HEICON** firmy **Sherpa Engineering**, sukcesor algorytmu **IDCOM** (Richalet i in, 1978), do 2006 r. rozwijanego i oferowanego przez firmę **Adersa**,
- **SMOC (Supervisory Multivariable Optimizing Controller)** oferowany przez **Shell Global Solutions**,
- **3dMPC** oferowany przez firmę **ABB**,
- **Profit Controller** i **Profit NLC Controller** (Nonlinear Controller) firmy **Honeywell** (elementy szerszego środowiska Profit Suite),
- **Pavilion8** firmy **Pavilion Technologies** (grupa **Rockwell Automation**),
- **Connoisseur** firmy **Invensys**,
- **INCA MPC** firmy **IPCOS**,
- **DeltaV PredictPro** firmy **Emerson** (może być też realizowany w sterownikach systemu DCS DeltaV),
- **MVC** firmy **GE Energy** (dawniej produkt firmy **Continental Controls**).

ZASADA REGULACJI PREDYKCYJNEJ (rysunek dla $n_u = 1, n_y = 1$)



- $y^{zad}(k+p|k)$ – wartość zadana wyjść regulowanych (**przewidywana na chwilę $k+p$, w chwili k**),
- $y(k+p|k)$ – wartość wyjść regulowanych przewidywana na chwilę $k+p$, w chwili k ,
- $u(k+p|k)$ – wartość sterowań (wyjść regulatora),
- $\Delta u(k|k) = u(k|k) - u(k-1)$ – przyrost sterowania w chwili bieżącej k (do zastosowania w procesie jako $\Delta u(k)$),
- $\Delta u(k+p|k) = u(k+p|k) - u(k+p-1|k)$ – przyrosty sterowań w przyszłych chwilach, $p = 1, \dots, N_u - 1$,
- N – **horyzont predykcji (horyzont optymalizacji)**,
- N_u – **horyzont sterowania** (zmian sterowania), $N_u \leq N$, dla $p = N_u, \dots, N - 1$ zakładamy $\Delta u(k+p|k) = 0$,

ZASADA REGULACJI PREDYKCYJNEJ 2

Zadanie optymalizacji dynamicznej regulatora MPC ($y \in \mathbb{R}^{n_y}$, $u \in \mathbb{R}^{n_u}$):

$$\min_{\Delta u(k|k), \dots, \Delta u(k+N_u-1|k)} \left\{ J(k) = \sum_{p=1}^N \|y^{zad}(k+p|k) - y(k+p|k)\|^2 + \lambda \sum_{p=0}^{N_u-1} \|\Delta u(k+p|k)\|^2 \right\}$$

z ograniczeniami: $u_{min} \leq u(k+p|k) \leq u_{max}$, $p = 0, \dots, N_u - 1$

$$-\Delta u_{max} \leq \Delta u(k+p|k) \leq \Delta u_{max}, \quad p = 0, \dots, N_u - 1$$

$$y_{min} \leq y(k+p|k) \leq y_{max}, \quad p = 1, \dots, N$$

gdzie: λ – współczynnik kary ważący sumę kar za zmienność wyliczanych sterowań w stosunku do sumy kar za przewidywane błędy regulacji, a wartości $y(k+p|k)$ wyliczane są z modelu procesu (ograniczenie równościowe).

$y \in \mathbb{R}^{n_y}$, $u \in \mathbb{R}^{n_u}$ – to wektory (w ogólności $n_y \neq n_u$), stąd funkcję celu $J(k)$ można zapisać w rozwinięciu na składowe:

$$J(k) = \sum_{p=1}^N \sum_{i=1}^{n_y} (y_i^{zad}(k+p|k) - y_i(k+p|k))^2 + \lambda \sum_{p=0}^{N_u-1} \sum_{i=1}^{n_u} (\Delta u_i(k+p|k))^2$$

Uwaga 1: wyżej podano jedynie najprostsze postacie ograniczeń – na wartości sterowań i wyjść oraz przyrosty sterowań. Ograniczenia mogą być bardziej złożone (na dowolne funkcje sterowań i wyjść – komplikuje to nieco zadania optymalizacji).

ZASADA REGULACJI PREDYKCYJNEJ 3

Uwaga 2: Podana funkcja celu ma najprostszą postać ważenia przyrostów sterowań w stosunku do błędów regulacji na horyzoncie predykcji – jeden współczynnik λ . Możliwe są i stosowane bardziej ogólne postacie, z różnymi współczynnikami przy kwadratach przyrostów sterowań i przy kwadratach błędów regulacji, jeśli to potrzebne:

$$J(k) = \sum_{p=1}^N \sum_{i=1}^{n_y} \psi_i \left(y_i^{zad}(k+p|k) - y_i(k+p|k) \right)^2 + \sum_{p=0}^{N_u-1} \sum_{i=1}^{n_u} \lambda_i \left(\Delta u_i(k+p|k) \right)^2$$

W zapisie wektorowym:

$$J(k) = \sum_{p=1}^N \left(y^{zad}(k+p|k) - y(k+p|k) \right)^T \Psi \left(y^{zad}(k+p|k) - y(k+p|k) \right) + \sum_{p=0}^{N_u-1} \left(\Delta u(k+p|k) \right)^T \Lambda \left(\Delta u(k+p|k) \right),$$

gdzie

$$\Psi = \begin{bmatrix} \psi_1 & 0 & 0 & 0 \\ 0 & \psi_2 & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \psi_{n_y} \end{bmatrix}, \quad \Lambda = \begin{bmatrix} \lambda_1 & 0 & 0 & 0 \\ 0 & \lambda_2 & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \lambda_{n_u} \end{bmatrix}.$$

Wygodny zapis:

$$J(k) = \sum_{p=1}^N \left\| y^{zad}(k+p|k) - y(k+p|k) \right\|_{\Psi}^2 + \sum_{p=0}^{N_u-1} \left\| \Delta u(k+p|k) \right\|_{\Lambda}^2 \quad \left(\|x\|_{\mathbf{A}} \stackrel{\text{df}}{=} \sqrt{x^T \mathbf{A} x} \right)$$

ZASADA REGULACJI PREDYKCYJNEJ 4

Dla wyznaczania trajektorii $y(k + p|k)$, $p = 1, \dots, N$, niezbędne jest dysponowanie **modelem obiektu regulacji** – w ogólności nieliniowym.

Największe znaczenie praktyczne mają **algorytmy MPC z modelami liniowymi**, gdyż:

- szeroki jest zakres ich bezpośredniego zastosowania,
- stanowią one podstawę konstrukcji stosunkowo prostych i często skutecznych algorytmów nieliniowych z linearyzacjami modelu nieliniowego.

W przypadku **liniowym, korzystając z zasady superpozycji**, można przedstawić trajektorię $\{y(k + p|k), p = 1, \dots, N\}$ w postaci sumy:



$$y(k + p|k) = y^0(k + p|k) + \Delta y(k + p|k), \quad p = 1, \dots, N,$$

- **trajektorii swobodnej** $\{y^0(k + p|k), p = 1, \dots, N\}$, zależnej tylko od już zrealizowanych (przeszłych) sterowań, oraz
- **trajektorii wymuszanej** $\{\Delta y(k + p|k), p = 1, \dots, N\}$, zależnej tylko od zmiennych decyzyjnych $\Delta u(k + p|k), p = 0, \dots, N_u - 1$.

Dekompozycja ta jest **wygodna** (ale **nie konieczna**) dla realizacji algorytmu MPC, gdyż:

- wartości $y^0(k + p|k)$ oblicza się w danym kroku czasowym k **tylko jeden raz** (zależą tylko od przeszłych danych), dalej to parametry w zadaniu optymalizacji sterowania,
- **przyrosty** $\Delta y(k + p|k), p = 1, \dots, N$ wyliczane są **wielokrotnie** w procesie optymalizacji sterowania, **zależą od wyznaczanych zmian sterowania** $\Delta u(k + p|k), p = 0, \dots, N_u - 1$.

ZASADA REGULACJI PREDYKCYJNEJ – z modelem liniowym



ZASADA REGULACJI PREDYKCyjNEJ – z modelem liniowym 2

Stosując dekompozycję prognozowanej trajektorii wyjść, mamy funkcję kryterialną:

$$J(k) = \sum_{p=1}^N \left\| y^{zad}(k+p|k) - y^0(k+p|k) - \Delta y(k+p|k) \right\|_{\Psi}^2 + \sum_{p=0}^{N_u-1} \left\| \Delta u(k+p|k) \right\|_{\Lambda}^2$$

Oznaczmy przez \mathbf{M}_p operatory liniowe (tzn. macierze) opisujące zależność elementów trajektorii wymuszanej $\Delta y(k+p|k)$ od zmiennych decyzyjnych:

$$\Delta y(k+p|k) = \mathbf{M}_p \cdot \begin{bmatrix} \Delta u(k|k) \\ \Delta u(k+1|k) \\ \vdots \\ \Delta u(k+N_u-1|k) \end{bmatrix} = \mathbf{M}_p \cdot \Delta U(k), \quad p = 1, \dots, N,$$

$\Delta U(k)$ – wektor wszystkich zmiennych decyzyjnych o długości $n_u \times N_u$ ($u(k) \in \mathbb{R}^{n_u}$).

Zadanie optymalizacji dynamicznej regulatora predykcyjnego dostajemy w postaci:

$$\min_{\Delta U(k)} \left\{ J(k) = \sum_{p=1}^N \left\| y^{zad}(k+p|k) - y^0(k+p|k) - \mathbf{M}_p \Delta U(k) \right\|_{\Psi}^2 + \sum_{p=0}^{N_u-1} \left\| \Delta u(k+p|k) \right\|_{\Lambda}^2 \right\}$$

z ograniczeniami :

$$u_{min} \leq u(k+p|k) \leq u_{max}, \quad p = 0, \dots, N_u - 1$$
$$-\Delta u_{max} \leq \Delta u(k+p|k) \leq \Delta u_{max}, \quad p = 0, \dots, N_u - 1$$
$$y_{min} \leq y^0(k+p|k) + \mathbf{M}_p \Delta U(k) \leq y_{max}, \quad p = 1, \dots, N$$

ZASADA REGULACJI PREDYKCyjNEJ – z modelem liniowym 3

Zadanie optymalizacji dynamicznej regulatora predykcyjnego:

$$\min_{\Delta U(k)} \left\{ J(k) = \sum_{p=1}^N \|y^{ad}(k+p|k) - y^0(k+p|k) - \mathbf{M}_p \Delta U(k)\|_{\Psi}^2 + \sum_{p=0}^{N_u-1} \|\Delta u(k+p|k)\|_{\Lambda}^2 \right\}$$

z ograniczeniami :

$$\begin{aligned} u_{min} &\leq u(k+p|k) \leq u_{max}, \quad p = 0, \dots, N_u - 1 \\ -\Delta u_{max} &\leq \Delta u(k+p|k) \leq \Delta u_{max}, \quad p = 0, \dots, N_u - 1 \\ y_{min} &\leq y^0(k+p|k) + \mathbf{M}_p \Delta U(k) \leq y_{max}, \quad p = 1, \dots, N \end{aligned}$$

Jest to zadanie minimalizacji funkcji kwadratowej ściśle wypukłej, (co wynika z założenia $\Lambda > 0$ i $\Psi \geq 0$). Jest to więc zadanie:

- posiadające **jednoznaczne minimum** będące minimum globalnym,
- łatwe do rozwiązania analitycznego, jeśli nie ma ograniczeń,
- łatwe do szybkiego i niezawodnego rozwiązania numerycznego, gdy są ograniczenia.

Macierz

$$\mathbf{M} = \begin{bmatrix} \mathbf{M}_1 \\ \mathbf{M}_2 \\ \vdots \\ \mathbf{M}_N \end{bmatrix}, \quad \begin{bmatrix} \Delta y(k+1|k) \\ \Delta y(k+2|k) \\ \vdots \\ \Delta y(k+N|k) \end{bmatrix} = \begin{bmatrix} \mathbf{M}_1 \\ \mathbf{M}_2 \\ \vdots \\ \mathbf{M}_N \end{bmatrix} \cdot \begin{bmatrix} \Delta u(k|k) \\ \Delta u(k+1|k) \\ \vdots \\ \Delta u(k+N_u-1|k) \end{bmatrix} = \mathbf{M} \cdot \Delta U(k)$$

nazywana jest **macierzą dynamiczną** (*dynamic matrix*).

ZWIĘZŁY WEKTOROWY ZAPIS FUNKCJI CELU (z modelem liniowym)

Zdefiniujmy wektory kolumnowe $Y^{zad}(k)$, $Y^0(k)$ i $\Delta Y(k)$, o długości $n_y \cdot N$ każdy (N – horyzont predykcji, $n_y = \dim y$ – liczba wyjść obiektu):

$$Y^{zad}(k) = \begin{bmatrix} y^{zad}(k+1|k) \\ y^{zad}(k+2|k) \\ \vdots \\ y^{zad}(k+N|k) \end{bmatrix}, \quad Y^0(k) = \begin{bmatrix} y^0(k+1|k) \\ y^0(k+2|k) \\ \vdots \\ y^0(k+N|k) \end{bmatrix}, \quad \Delta Y(k) = \begin{bmatrix} \Delta y(k+1|k) \\ \Delta y(k+2|k) \\ \vdots \\ \Delta y(k+N|k) \end{bmatrix}$$

oraz macierze diagonalne $\underline{\Psi}$ i $\underline{\Lambda}$ o wymiarowościach $(n_y \cdot N) \times (n_y \cdot N)$ i $(n_u \cdot N_u) \times (n_u \cdot N_u)$, odpowiednio ($n_u = \dim u$ jest liczbą sterowań obiektu):

$$\underline{\Psi} = \text{diag}\{\underbrace{\Psi, \dots, \Psi}_{N \text{ razy}}\} = \underbrace{\begin{bmatrix} \Psi & 0 & \dots & 0 \\ 0 & \Psi & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \Psi \end{bmatrix}}_{N \text{ kolumn}}, \quad \underline{\Lambda} = \text{diag}\{\underbrace{\Lambda, \dots, \Lambda}_{N_u \text{ razy}}\} = \underbrace{\begin{bmatrix} \Lambda & 0 & \dots & 0 \\ 0 & \Lambda & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \Lambda \end{bmatrix}}_{N_u \text{ kolumn}}$$

ZWIĘZŁY WEKTOROWY ZAPIS FUNKCJI CELU (z modelem liniowym) 2

Funkcję celu

$$\begin{aligned}
 J(k) &= \sum_{p=1}^N \|y^{zad}(k+p|k) - y^0(k+p|k) - \mathbf{M}_p \triangle U(k)\|_{\underline{\Psi}}^2 + \sum_{p=0}^{N_u-1} \|\triangle u(k+p|k)\|_{\underline{\Lambda}}^2 \\
 &= \sum_{p=1}^N (y^{zad}(k+p|k) - y^0(k+p|k) - \mathbf{M}_p \triangle U(k))^T \underline{\Psi} (y^{zad}(k+p|k) - y^0(k+p|k) - \mathbf{M}_p \triangle U(k)) \\
 &\quad - y^0(k+p|k) - \mathbf{M}_p \triangle U(k)) + \sum_{p=0}^{N_u-1} \triangle u(k+p|k)^T \underline{\Lambda} \triangle u(k+p|k)
 \end{aligned}$$

można teraz zapisać w zwartej postaci:

$$\begin{aligned}
 J(k) &= (Y^{zad}(k) - Y^0(k) - \mathbf{M} \triangle U(k))^T \underline{\Psi} (Y^{zad}(k) - Y^0(k) - \mathbf{M} \triangle U(k)) + \\
 &\quad + \triangle U(k)^T \underline{\Lambda} \triangle U(k) \\
 &= \|[Y^{zad}(k) - Y^0(k) - \mathbf{M} \triangle U(k)]\|_{\underline{\Psi}}^2 + \|\triangle U(k)\|_{\underline{\Lambda}}^2
 \end{aligned}$$

Dla $\underline{\Psi} = \mathbf{I}$, $\underline{\Lambda} = \lambda \mathbf{I}$:

$$J(k) = \|Y^{zad}(k) - Y^0(k) - \mathbf{M} \triangle U(k)\|^2 + \lambda \|\triangle U(k)\|^2.$$

ANALITYCZNE PRAWO STEROWANIA MPC (z modelem liniowym)

Jeśli pominąć ograniczenia, to zadanie optymalizacji regulatora MPC z modelem liniowym sprowadza się do **minimalizacji bez ograniczeń funkcji kwadratowej ściśle wypukłej**:

$$\begin{aligned}\min_{\Delta U(k)} \{ J(k) &= \| Y^{zad}(k) - Y^0(k) - \mathbf{M} \Delta U(k) \|^2_{\underline{\Psi}} + \| \Delta U(k) \|^2_{\underline{\Lambda}} \\ &= (Y^{zad}(k) - Y^0(k) - \mathbf{M} \Delta U(k))^T \underline{\Psi} (Y^{zad}(k) - Y^0(k) - \mathbf{M} \Delta U(k)) + \\ &\quad + \Delta U(k)^T \underline{\Lambda} \Delta U(k) \} \end{aligned}$$

Warunek minimum to **zero pochodnej (gradientu)**. Mamy ogólnie:

$$(x^T \mathbf{A} x)' = 2x^T \mathbf{A}, \quad \nabla (x^T \mathbf{A} x) = 2\mathbf{A}^T x,$$

stąd **zero pochodnej $J(k)$** :

$$2 (Y^{zad}(k) - Y^0(k) - \mathbf{M} \Delta U(k))^T \underline{\Psi} \cdot (-\mathbf{M}) + 2\Delta U(k)^T \underline{\Lambda} = 0^T,$$

zero gradientu $J(k)$:

$$-2\mathbf{M}^T \underline{\Psi} (Y^{zad}(k) - Y^0(k) - \mathbf{M} \Delta U(k)) + 2\Delta U(k)^T \underline{\Lambda} = 0,$$

czyli warunek minimum:

$$[\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}] \Delta U(k) = \mathbf{M}^T \underline{\Psi} [Y^{zad}(k) - Y^0(k)].$$

ANALITYCZNE PRAWO STEROWANIA MPC (z modelem liniowym) 2

Warunek minimum:

$$[\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}] \Delta U(k) = \mathbf{M}^T \underline{\Psi} [Y^{zad}(k) - Y^0(k)].$$

gdzie macierz $[\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}]$ jest kwadratowa i nieosobliwa (jest dodatnio określona).

Dostajemy stąd wektor optymalnych przyrostów sterowań $\Delta \hat{U}(k)$:

$$\begin{aligned} \Delta \hat{U}(k) &= [\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}]^{-1} \mathbf{M}^T \underline{\Psi} [Y^{zad}(k) - Y^0(k)] \\ &= \mathbf{K} [Y^{zad}(k) - Y^0(k)] \end{aligned}$$

gdzie

$$\mathbf{K} = [\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}]^{-1} \mathbf{M}^T \underline{\Psi} = \begin{bmatrix} \bar{\mathbf{K}}_1 \\ \bar{\mathbf{K}}_2 \\ \vdots \\ \bar{\mathbf{K}}_{N_u} \end{bmatrix} = \begin{bmatrix} \mathbf{K}_{1,1} & \mathbf{K}_{1,2} & \cdots & \mathbf{K}_{1,N} \\ \mathbf{K}_{2,1} & \mathbf{K}_{2,2} & \cdots & \mathbf{K}_{2,N} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{K}_{N_u,1} & \mathbf{K}_{N_u,2} & \cdots & \mathbf{K}_{N_u,N} \end{bmatrix}_{(n_u \cdot N_u) \times (n_y \cdot N)}$$

a każda podmacierz $\mathbf{K}_{i,j}$ jest o wymiarze $n_u \times n_y$.

Mamy:

$$\Delta \hat{U}(k) = \mathbf{K}[Y^{zad}(k) - Y^0(k)]$$

tn.

$$\begin{bmatrix} \Delta \hat{u}(k|k) \\ \vdots \\ \Delta \hat{u}(k+1|k) \end{bmatrix} = \begin{bmatrix} \bar{\mathbf{K}}_1 \\ \bar{\mathbf{K}}_2 \\ \vdots \\ \bar{\mathbf{K}}_N \end{bmatrix} \cdot \begin{bmatrix} y^{zad}(k+1|k) - y^0(k+1|k) \\ y^{zad}(k+2|k) - y^0(k+2|k) \\ \vdots \\ y^{zad}(k+N|k) - y^0(k+N|k) \end{bmatrix}$$

Prawo regulacji MPC (bez uwzględnienia ograniczeń):

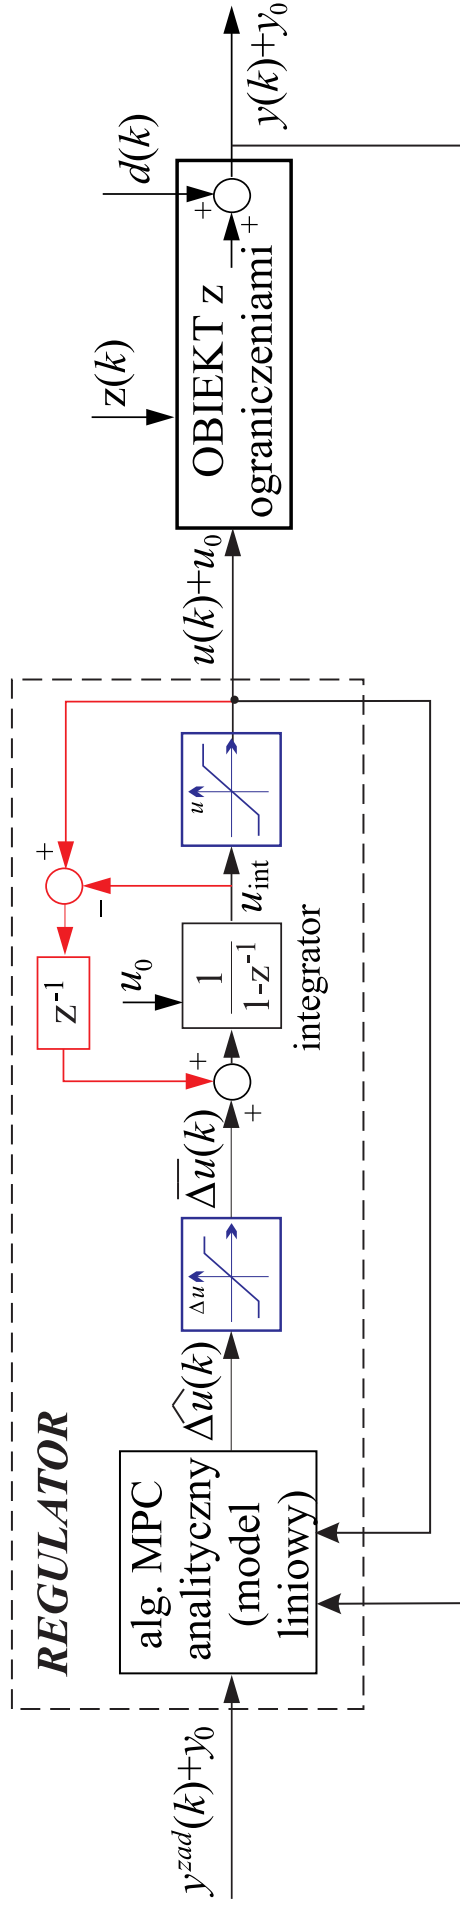
$$\Delta u(k) = \Delta \hat{u}(k|k) = \bar{\mathbf{K}}_1[Y^{zad}(k) - Y^0(k)],$$

gdzie $\bar{\mathbf{K}}_1$ – macierz o wymiarze $n_u \times (n_y \cdot N)$, złożona z pierwszych n_u wierszy macierzy \mathbf{K} .

Sprzężenie zwrotne:

Część swobodna trajektorii wyjść $Y^0(k)$ zależy od zmierzonych wyjść i podanych sterowań procesu: $Y^0(k) = Y^0(y(k), y(k-1), \dots, u(k-1), u(k-2), \dots)$ – **regulator** realizuje sprzężenie zwrotne od wyjść i sterowań procesu (też mierzonych i uwzględnianych w modelu zakłóceń).

Regulator analityczny MPC – przycinanie sterowania do ograniczeń



Regulator MPC z algorytmem analitycznym i z ograniczaniem szybkości zmian i amplitudy sterowania przez przycinanie sygnałów przyrostu sterowania i sterowania, oraz z mechanizmem anti-windup (górna pętla sprzężenia); $u(k), y(k), y^{zad}(k)$ – sygnały przyrostowe wokół punktu pracy (u_0, y_0).

Uwaga 1: Model obiektu liniowy \equiv zlinearyzowany w punkcie pracy (u_0, y_0). Załączamy regulator ze stanem początkowym integratora u_0 (pokazane na rysunku) – realizuje u_0 .

Uwaga 2: Realizacja programowa pętli anti-windup jest bardzo prosta: wystarczy integrator (sumator) zrealizować w postaci: $u_{int}(k+1) = (u(k) + u_0) + \Delta u(k)$.

Uwaga 3: sprzężenia zwrotne regulatorów MPC są od poprzednich wyjść (lub stanu) obiektu i sterowań (wejść obiektu) – zawsze od ograniczonych sterowań $u(k)$ działających na obiekt (a nie od nieograniczonych wynikających tylko z czystego prawa regulacji).

Zadanie optymalizacji dynamicznej regulatora MPC:

$$\min_{\Delta U(k)} \left\{ J(k) = \|Y^{zad}(k) - Y^0(k) - \mathbf{M} \Delta U(k)\|_{\underline{\Psi}}^2 + \|\Delta U(k)\|_{\underline{\Lambda}}^2 \right\}$$

$$\begin{aligned} \text{z ograniczeniami:} \quad & u_{min} \leq u(k + p|k) \leq u_{max}, \quad p = 0, \dots, N_u - 1 \\ & -\Delta u_{max} \leq \Delta u(k + p|k) \leq \Delta u_{max}, \quad p = 0, \dots, N_u - 1 \\ & y_{min} \leq y^0(k + p|k) + \mathbf{M}_p \Delta U(k) \leq y_{max}, \quad p = 1, \dots, N \end{aligned}$$

należy sprowadzić do postaci standardowej dla zadania programowania kwadratowego (QP, w Matlabie procedura "quadprog"):

$$\min \{ J(x) = \frac{1}{2} x^T \mathbf{H} x + f^T x \}$$

$$\text{z ogr.: } x_{\min} \leq x \leq x_{\max},$$

$$\mathbf{A}x \leq b,$$

która rozwiązywana jest w każdej chwili interwencji regulatora (zmiany sterowania).

W tym celu, przyjmując $x = \Delta U(k)$, trzeba odpowiednio przekształcić zapis funkcji celu i ograniczeń, aby wyznaczyć: \mathbf{H} , f , x_{min} , x_{max} , \mathbf{A} i b .

NUMERYCZNY ALGORYTM MPC z modelem liniowym 2

Przypomnijmy:

$$Y^{zad}(k) = \begin{bmatrix} y^{zad}(k+1|k) \\ y^{zad}(k+2|k) \\ \vdots \\ y^{zad}(k+N|k) \end{bmatrix}, \quad Y^0(k) = \begin{bmatrix} y^0(k+1|k) \\ y^0(k+2|k) \\ \vdots \\ y^0(k+N|k) \end{bmatrix}, \quad \Delta U(k) = \begin{bmatrix} \Delta u(k|k) \\ \Delta u(k+1|k) \\ \vdots \\ \Delta u(k+N_u-1|k) \end{bmatrix}$$

Funkcja celu: Oznaczając $x = \Delta U(k)$, $E^0(k) = Y^{zad}(k) - Y^0(k)$, mamy:

$$\begin{aligned} J(k) &= \|E^0(k) - \mathbf{M}x\|_{\underline{\Psi}}^2 + \|x\|_{\underline{\Lambda}}^2 = (E^0(k) - \mathbf{M}x)^T \underline{\Psi} (E^0(k) - \mathbf{M}x) + x^T \underline{\Lambda} x \\ &= E^0(k)^T \underline{\Psi} E^0(k) - E^0(k)^T \underline{\Psi} \mathbf{M}x - x^T \mathbf{M}^T \underline{\Psi} E^0(k) + x^T \mathbf{M}^T \underline{\Psi} \mathbf{M}x + x^T \underline{\Lambda} x \\ &= x^T [\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}] x - 2E^0(k)^T \underline{\Psi} \mathbf{M}x + E^0(k)^T \underline{\Psi} E^0(k) \\ &= x^T \mathbf{H}x - 2f^T x + E^0(k)^T \underline{\Psi} E^0(k), \end{aligned}$$

gdzie ostatni składnik jako stały nie wpływa na wynik optymalizacji (może być pominięty).

Ograniczenia wyjść: Definiując wektory Y_{\max} i Y_{\min} o długości $n_y \cdot N$:

$$Y_{\max} = \left\{ \begin{bmatrix} y_{\max} \\ \vdots \\ y_{\max} \end{bmatrix} \right\}_{y_{\max} \text{ } N \text{ razy}}, \quad Y_{\min} = \left\{ \begin{bmatrix} y_{\min} \\ \vdots \\ y_{\min} \end{bmatrix} \right\}_{y_{\min} \text{ } N \text{ razy}},$$

NUMERYCZNY ALGORYTM MPC z modelem liniowym 3

możemy ograniczenia wyjść

$$y_{min} \leq y^0(k + p|k) + \mathbf{M}_p \Delta U(k) \leq y_{max}, \quad p = 1, \dots, N,$$

zapisać w postaci

$$Y_{\min} \leq Y^0(k) + \mathbf{M} \Delta U(k) \leq Y_{\max}$$

Ograniczenia szybkości narastania sterowań

Przypomnijmy wektor $\Delta U(k)$ i zdefiniujmy wektor ΔU_{\max} :

$$\Delta U(k) = \begin{bmatrix} \Delta u(k|k) \\ \vdots \\ \Delta u(k + N_u - 1|k) \end{bmatrix}, \quad \Delta U_{\max} = \begin{bmatrix} \Delta u_{\max} \\ \vdots \\ \Delta u_{\max} \end{bmatrix} \left\} \Delta u_{\max} N_u \text{ razy},$$

możemy ograniczenia szybkości narastania sterowań

$$-\Delta u_{\max} \leq \Delta u(k + p|k) \leq \Delta u_{\max}, \quad p = 0, 1, \dots, N_u - 1$$

zapisać w postaci

$$-\Delta U_{\max} \leq \Delta U(k) \leq \Delta U_{\max}.$$

NUMERYCZNY ALGORYTM MPC z modelem liniowym 4

Ograniczenia wartości sterowań:

$$u_{\min} \leq u(k + p|k) \leq u_{\max}, \quad p = 0, 1, \dots, N_u - 1 \quad (u \in \mathbb{R}^{n_u}).$$

Po zdefiniowaniu następujących wektorów granic ograniczeń, o wymiarze $n_u \cdot N_u$,

$$U_{\min} = \underbrace{\begin{bmatrix} u_{\min}^T & \dots & u_{\min}^T \end{bmatrix}^T}_{N_u \text{ razy}}, \quad U_{\max} = \underbrace{\begin{bmatrix} u_{\max}^T & \dots & u_{\max}^T \end{bmatrix}^T}_{N_u \text{ razy}}$$

należy jeszcze **wyrazić wartości sterowań poprzez ich przyrosty**. Wykorzystując zależność

$$u(k + p|k) = u(k - 1) + \sum_{j=0}^p \Delta u(k + j|k), \quad p = 0, 1, \dots, N_u - 1$$

możemy ograniczenia wartości sterowań zapisać w postaci

$$U_{\min} \leq U(k - 1) + \mathbf{J} \Delta U(k) \leq U_{\max}$$

gdzie

$$U(k - 1) = \begin{bmatrix} u(k - 1) \\ \vdots \\ u(k - 1) \end{bmatrix} \Bigg\}^{u(k - 1) \text{ } N_u \text{ razy}}, \quad \mathbf{J} = \begin{bmatrix} \mathbf{I} & \mathbf{0} & \mathbf{0} & \mathbf{0} \\ \mathbf{I} & \mathbf{I} & \mathbf{0} & \mathbf{0} \\ \mathbf{I} & \mathbf{I} & \mathbf{I} & \mathbf{0} \\ \mathbf{I} & \mathbf{I} & \mathbf{I} & \mathbf{I} \end{bmatrix}_{N_u \cdot n_u \times N_u \cdot n_u},$$

a każda z macierzy jednostkowych \mathbf{I} jest o wymiarze $n_u \times n_u$.

NUMERYCZNY ALGORYTM MPC z modelem liniowym 5

Reasumując, przyjmując:

$$x = \Delta U(k), \quad x_{\min} = -\Delta U_{\max}, \quad x_{\max} = \Delta U_{\max},$$

$$\mathbf{H} = 2(\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}),$$

$$f = -2\mathbf{M}^T \underline{\Psi} (Y^{zad}(k) - Y^0(k)),$$

$$\mathbf{A} = \begin{bmatrix} -\mathbf{J} \\ \mathbf{J} \\ -\mathbf{M} \\ \mathbf{M} \end{bmatrix}, \quad b = \begin{bmatrix} -U_{\min} + U(k-1) \\ U_{\max} - U(k-1) \\ -Y_{\min} + Y^0(k) \\ Y_{\max} - Y^0(k) \end{bmatrix}$$

dostajemy **zadanie optymalizacji regulatora MPC w postaci standardowej dla zadania programowania kwadratowego**:

$$\min \{J(x) = \frac{1}{2} x^T \mathbf{H} x + f^T x\}$$

z ograniczeniami : $x_{\min} \leq x \leq x_{\max}$,

$$\mathbf{A}x \leq b.$$

Uwaga: macierze \mathbf{H} i \mathbf{A} są **stałe i wyznaczamy je "off-line"**, wektory f i b zależą od $Y^0(k)$ i $U(k-1)$ (tj. bieżących danych) – **wyznaczamy je "on-line", w każdym kroku k regulatora**.

PODSUMOWANIE – MPC z modelem liniowym

Reasumując, w każdym kroku regulatora MPC rozwiązywane jest zadanie optymalizacji:

$$\min_{\Delta U(k)} \{ \|Y^{zad}(k) - Y^0(k) - \mathbf{M}\Delta U(k)\|_{\underline{\Psi}}^2 + \|\Delta U(k)\|_{\underline{\Lambda}}^2 \}$$

z ograniczeniami: $-\Delta U_{\max} \leq \Delta U(k) \leq \Delta U_{\max}$

$$U_{\min} \leq U(k-1) + \mathbf{J}\Delta U(k) \leq U_{\max}$$

$$Y_{\min} \leq Y^0(k) + \mathbf{M}\Delta U(k) \leq Y_{\max}$$

gdzie $Y^0(k)$ zależy od bieżących pomiarów i modelu, a \mathbf{M} od modelu obiektu.

— Jeśli nie uwzględniamy ograniczeń, to wektor optymalnych sterowań dany jest wzorem:

$$\Delta \hat{U}(k) = [\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}]^{-1} \mathbf{M}^T \underline{\Psi} [Y^{zad}(k) - Y^0(k)] = \mathbf{K} [Y^{zad}(k) - Y^0(k)],$$

a **prawo regulacji MPC** ma postać: $\Delta u(k) = \Delta \hat{u}(k|k) = \bar{\mathbf{K}}_1 [Y^{zad}(k) - Y^0(k)]$, gdzie $\bar{\mathbf{K}}_1$ składa się z n_u pierwszych wierszy macierzy \mathbf{K} .

— Jeśli uwzględniamy ograniczenia, to wektor optymalnych sterowań $\Delta \hat{U}(k)$ wynika z numerycznego rozwiązania zadania optymalizacji standardową procedurą QP, dla której:

$$\mathbf{H} = 2(\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}), \quad f = -2\mathbf{M}^T \underline{\Psi} [Y^{zad}(k) - Y^0(k)],$$

$$\mathbf{A} = \begin{bmatrix} -\mathbf{J} \\ \mathbf{J} \\ -\mathbf{M} \\ \mathbf{M} \end{bmatrix}, \quad b = \begin{bmatrix} -U_{\min} + U(k-1) \\ U_{\max} - U(k-1) \\ -Y_{\min} + Y^0(k) \\ Y_{\max} - Y^0(k) \end{bmatrix}$$

ZAPEWNIENIE NIEPUSTOŚCI ZBIORU DOPUSZCZALNEGO

Wartości elementów wektora wyjść prognozowanych $Y^0(k)$ zależą od aktualnych wartości zakłóceń w każdej z kolejnych chwil czasu k , **przesuwających granice ograniczeń w zadaniu optymalizacji QP** — stąd wpływ zakłóceń może spowodować, że w pewnych chwilach zbiór dopuszczalny zadania QP **będzie pusty** (może wystąpić jedynie gdy są ograniczenia na sterowania i wyjścia).

Regulator nie będzie w stanie wyznaczyć wartości sterowań – tak się nie może zdarzyć przy sterowaniu w czasie rzeczywistym, muszą być wprowadzone zabezpieczenia.

Prostym sposobem jest **potraktowanie ograniczeń wyjść jako ograniczeń miękkich**, tzn. takich, które **mogą być chwilowo naruszane**.

Naruszenia te powinny być jak najmniej, stąd zadanie optymalizacji regulatora MPC ma wówczas postać:

$$\min_{\Delta U(k), E_{min}, E_{max}} \{ \|Y^{zad}(k) - Y^0(k) - \mathbf{M}\Delta U(k)\|_{\underline{\Psi}}^2 + \|\Delta U(k)\|_{\underline{\Delta}}^2 + \rho_m \|E_{min}\|^2 + \rho_{max} \|E_M\|^2 \}$$

z ograniczeniami :

$$\begin{aligned} -\Delta U_{\max} &\leq \Delta U(k) \leq \Delta U_{\max}, \\ U_{\min} &\leq U(k-1) + \mathbf{J}\Delta U(k) \leq U_{\max}, \\ -E_{min} + Y_{\min} &\leq Y^0(k) + \mathbf{M}\Delta U(k) \leq Y_{\max} + E_{max}, \\ E_{min} &\geq 0, \quad E_{max} \geq 0, \end{aligned}$$


gdzie E_{min}, E_{max} są dodatkowymi zmiennymi relaksującymi ograniczenia, a ρ_m, ρ_M współczynniki kary.

(Priorytetyzacja ograniczeń, różnicowanie naruszeń i kar w zależności od chwili czasu.)

REGULACJA ZAKRESOWA (*range control*)

W wielu zastosowaniach wymaganiem jest, aby zmienna regulowana $y(k)$ była nie na określonej wartości zadanej y^{zad} , ale **jedynie w określonym zakresie**:

$$y_{min} \leq y(k) \leq y_{max}$$



Przykłady:

- regulacja stężenia chloru w wodzie w punktach odbioru wody komunalnej,
- regulacja poziomu cieczy w zbiorniku buforowym.

Takie zmienne procesowe nazywamy **zmiennymi ograniczonymi** (*constraint variable – CV*).

REGULACJA ZAKRESOWA (*range control*) 2

Jeśli:

- zdefiniujemy dla zmiennej ograniczonej $y_j(k)$ wartość zadaną jako

$$y_j^{zad}(k) = y_{j,sred}(k) = 0.5(y_{j,min} + y_{j,max})$$

- przyjmiemy wartość elementu ψ_j macierzy Ψ (współczynnika kary) odpowiadającego tej zmiennej na bardzo małej wartości (w stosunku do pozostałych),

to możemy dla takich zmiennych **stosować standardową postać zadania optymalizacji MPC**, konieczne z traktowaniem ograniczeń na zmienne wyjściowe, **przede wszystkim ograniczeń $y_{min} \leq y(k) \leq y_{max}$ na zmienne ograniczone CV, jako ograniczenia "miękkie"**, możliwe do przejściowego naruszenia:

$$\min_{\Delta U(k), \bar{E}_{min}, \bar{E}_{max}} \{ \|Y^{zad}(k) - Y^0(k) - \mathbf{M}\Delta U(k)\|_{\underline{\Psi}}^2 + \|\Delta U(k)\|_{\underline{\Delta}}^2 + \rho_m \|E_{min}\|^2 + \rho_{max} \|E_{max}\|^2 \}$$

z ograniczeniami : $-\Delta U_{max} \leq \Delta U(k) \leq \Delta U_{max}$,

$$U_{min} \leq U(k-1) + \mathbf{J}\Delta U(k) \leq U_{max},$$

$$-\bar{E}_{min} + Y_{min} \leq Y^0(k) + \mathbf{M}\Delta U(k) \leq Y_{max} + \bar{E}_{max},$$

$$0 \leq \bar{E}_{min} \leq Y_{min} - Y_{MIN},$$

$$0 \leq \bar{E}_{max} \leq Y_{MAX} - Y_{max},$$

WYZNACZANIE PRAWA STEROWANIA MPC (z modelem liniowym)

Macierz $\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}$ może być źle uwarunkowana numerycznie (szczególnie dla dużych wartości N i małych wartości elementów $\underline{\Lambda}$) – wówczas wyznaczenie \mathbf{K} z wzoru $\mathbf{K} = [\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}]^{-1} \mathbf{M}^T \underline{\Psi}$ jest niekorzystne numerycznie.

Zalecane jest wtedy sprowadzenie zadania optymalizacji MPC do postaci LZNK (liniowego zadania najmniejszych kwadratów) i wykorzystanie dekompozycji QR (lub SVD).

Sprowadzenie zadania optymalizacji MPC do postaci LZNK:

Ponieważ $\underline{\Psi} \geq 0$, $\underline{\Lambda} > 0$ i są diagonalne, to można je przedstawić w postaci

$$\underline{\Psi} = \mathbf{S}_{\Psi}^T \mathbf{S}_{\Psi}, \quad \underline{\Lambda} = \mathbf{S}_{\Lambda}^T \mathbf{S}_{\Lambda} \quad (\mathbf{S}_{\Psi} = \sqrt{\underline{\Psi}}, \quad \mathbf{S}_{\Lambda} = \sqrt{\underline{\Lambda}}).$$

Funkcja kryterialna $J(k)$ może być wówczas zapisana w postaci

$$\begin{aligned} J(k) &= (Y^{zad}(k) - Y^0(k) - \mathbf{M} \triangle U(k))^T \mathbf{S}_{\Psi}^T \cdot \mathbf{S}_{\Psi} (Y^{zad}(k) - Y^0(k) - \mathbf{M} \triangle U(k)) + \\ &\quad + \triangle U(k)^T \mathbf{S}_{\Lambda}^T \cdot \mathbf{S}_{\Lambda} \triangle U(k) \\ &= \|\mathbf{S}_{\Psi} (Y^{zad}(k) - Y^0(k) - \mathbf{M} \triangle U(k))\|^2 + \|\mathbf{S}_{\Lambda} \triangle U(k)\|^2 \\ &= \left\| \begin{bmatrix} \mathbf{S}_{\Psi} (Y^{zad}(k) - \mathbf{M} \triangle U(k) - Y^0(k)) \\ \mathbf{S}_{\Lambda} \triangle U(k) \end{bmatrix} \right\|^2 \\ &= \left\| \begin{bmatrix} -\mathbf{S}_{\Psi} \mathbf{M} \triangle U(k) + \mathbf{S}_{\Psi} (Y^{zad}(k) - Y^0(k)) \\ \mathbf{S}_{\Lambda} \triangle U(k) - 0 \end{bmatrix} \right\|^2 \end{aligned}$$

WYZNACZANIE PRAWA STEROWANIA MPC (z modelem liniowym) 2

Funkcję celu zadania minimalizacji MPC możemy więc zapisać w postaci:

$$J(k) = \left\| \begin{bmatrix} \mathbf{S}_\Psi \mathbf{M} \Delta U(k) - \mathbf{S}_\Psi (Y^{zad}(k) - Y^0(k)) \\ \mathbf{S}_\Lambda \Delta U(k) - 0 \end{bmatrix} \right\|^2,$$

czyli minimalizacja $J(k)$ jest rozwiązaniem metodą najmniejszych kwadratów równania wektorowego (układ m równań z n niewiadomymi, $m > n$):

$$\begin{bmatrix} \mathbf{S}_\Psi \mathbf{M} \\ \mathbf{S}_\Lambda \end{bmatrix} \Delta U(k) = \begin{bmatrix} \mathbf{S}_\Psi (Y^{zad}(k) - Y^0(k)) \\ 0 \end{bmatrix} \Leftrightarrow \mathbf{A}x = b \quad (x = \Delta U(k))$$

Dla przypadku gdy $\Psi = \mathbf{I}$, $\Lambda = \lambda \mathbf{I}$ mamy: $\mathbf{S}_\Psi = \mathbf{I}$, $\mathbf{S}_\Lambda = \sqrt{\lambda} \mathbf{I}$, czyli równanie ma postać:

$$\begin{bmatrix} \mathbf{M} \\ \sqrt{\lambda} \mathbf{I} \end{bmatrix} \Delta U(k) = \begin{bmatrix} (Y^{zad}(k) - Y^0(k)) \\ 0 \end{bmatrix} \Leftrightarrow \mathbf{A}x = b$$

ROZKŁAD QR, rozwiązanie LZNK przy pełnym rzędzie macierzy^{*)}

Twierdzenie (rozkład QR wąski):

Macierz $A_{m \times n}$ ($m \geq n$) pełnego rzędu (równego n) można przedstawić w postaci iloczynu macierzy:

$$A_{m \times n} = Q_{m \times n} R_{n \times n},$$

gdzie:

- macierz $Q_{m \times n}$ spełnia $Q^T Q = I_{n \times n}$ (tzn. ma kolumny wzajemnie ortonormalne),
- macierz $R_{n \times n}$ trójkątna górna o dodatnich elementach na diagonalu (stąd nieosobliwa).

Twierdzenie (rozwiązanie LZNK przy pełnym rzędzie macierzy^{*)}):

Jeśli macierz $A \in \mathbb{R}^{m \times n}$, $m \geq n$, jest pełnego rzędu (równego n), to rozwiązanie układu m równań liniowych $Ax = b$ metodą najmniejszych kwadratów można uzyskać poprzez:

1. rozwiązanie układu n równań normalnych:

$$A^T A x = A^T b,$$

2. rozwiązanie układu n równań z kwadratową, nieosobliwą macierzą R :

$$R x = Q^T b,$$

gdzie Q i R są macierzami rozkładu QR (wąskiego) macierzy A .

Uwaga: $\text{cond}(R) = \text{cond}(A)$, $\text{cond}(A^T A) = (\text{cond}(A))^2$!

^{*)} zob. np. P. Tatjewski: "Metody numeryczne", Oficyna Wydawn. PW, 2013.

ROZKŁAD QR, rozwiązanie LZNK metodą rozkładu QR 2*)

Dowód twierdzenia o rozwiązaniu LZNK przy pełnym rzędzie macierzy:

LZNK jest zadaniem minimalizacji następującej funkcji kwadratowej:

$$J(x) = \|Ax - b\|^2 = (Ax - b)^T (Ax - b) = x^T A^T Ax - 2x^T A^T b + b^T b.$$

Warunek konieczny minimum tej funkcji – zerowanie jej gradientu:

$$\nabla J(x) = J'(x)^T = 2A^T Ax - 2A^T b = 0,$$

stąd wynika układ równań liniowych (zwany **układem równań normalnych**): $A^T Ax = A^T b$.

(co odpowiada uzyskanemu uprzednio wzorowi, macierz $K = (A^T A)^{-1} A^T$).

Korzystając z rozkładu wąskiego QR macierzy A : $A = QR$ ($A_{m \times n} = Q_{m \times n} R_{n \times n}$), układ równań normalnych możemy zapisać w postaci

$$R^T Q^T QRx = R^T Q^T b \Rightarrow R^T Rx = R^T Q^T b,$$

gdyż $Q^T Q = I$. Ponieważ macierz R jest nieosobliwa, to mnożąc obie strony lewostronnie przez $(R^T)^{-1}$, dostajemy następujący dobrze określony układ równań liniowych

$$Rx = Q^T b, \quad (\text{co odpowiada macierzy } K = R^{-1} Q^T)$$

co było do wykazania.

*) *materiał uzupełniający*

WYZNACZANIE PRAWA STEROWANIA MPC (z modelem liniowym) 3

$$\begin{bmatrix} \mathbf{S}_\Psi \mathbf{M} \\ \mathbf{S}_\Lambda \end{bmatrix} \Delta U(k) = \begin{bmatrix} \mathbf{S}_\Psi (Y^{zad}(k) - Y^0(k)) \\ 0 \end{bmatrix} \Leftrightarrow \mathbf{A} \cdot \Delta U(k) = b \quad (*)$$

Macierz Λ (czy $\lambda \mathbf{I}$) jest nieosobliwa, stąd macierz (kwadratowa) $\mathbf{S}_\Lambda = \sqrt{\Lambda}$ (czy $\sqrt{\lambda} \mathbf{I}$) jest też nieosobliwa (pełnego rzędu), a stąd macierz $\mathbf{A} = \begin{bmatrix} \mathbf{S}_\Psi \mathbf{M} \\ \mathbf{S}_\Lambda \end{bmatrix}$ jest też pełnego rzędu. **Dokonując rozkładu QR (wąskiego)** macierzy \mathbf{A} (np w Matlabie: $[\mathbf{Q}, \mathbf{R}] = \text{qr}(\mathbf{A}, 0)$;) mamy:

$$\mathbf{QR} \cdot \Delta U(k) = \begin{bmatrix} \mathbf{S}_\Psi (Y^{zad}(k) - Y^0(k)) \\ 0 \end{bmatrix}$$

Stąd wektor optymalnych sterowań regulatora MPC jest rozwiązaniem układu równań:

$$\mathbf{R} \cdot \Delta U(k) = \mathbf{Q}^T \begin{bmatrix} \mathbf{S}_\Psi (Y^{zad}(k) - Y^0(k)) \\ 0 \end{bmatrix}$$

Dla wyznaczenia macierzy \mathbf{K} mnożymy obie strony przez \mathbf{R}^{-1} (\mathbf{R} jest nieosobliwa), skąd:

$$\begin{aligned} \Delta \hat{U}(k) &= \mathbf{R}^{-1} \mathbf{Q}^T \begin{bmatrix} \mathbf{S}_\Psi (Y^{zad}(k) - Y^0(k)) \\ 0 \end{bmatrix} = [\mathbf{P}_1 \mathbf{P}_2] \begin{bmatrix} \mathbf{S}_\Psi (Y^{zad}(k) - Y^0(k))_{N \cdot n_y \times 1} \\ 0_{N_u n_u \times 1} \end{bmatrix} \\ &= \mathbf{P}_1 \mathbf{S}_\Psi (Y^{zad}(k) - Y^0(k)), \quad (\mathbf{P}_1)_{N_u \cdot n_u \times N \cdot n_y} \end{aligned}$$

Stąd $\mathbf{K} = \mathbf{P}_1 \mathbf{S}_\Psi$ (dla $\mathbf{\Psi} = \mathbf{I}$: $\mathbf{K} = \mathbf{P}_1$), $\Delta u(k) = \bar{\mathbf{K}}_1 [Y^{zad}(k) - Y^0(k)]$.

(\mathbf{K} można też wyznaczyć rozwiązując równanie (*) *metodą rozkładu SVD* macierzy \mathbf{A} .)

Wyznaczanie macierzy wzmocnień regulatora analitycznego – PODSUMOWANIE:

Sprawdzamy uwarunkowanie numeryczne macierzy $\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}$ dla przewidywanych wartości współczynników kary λ_i , $i = 1, \dots, n_u$ (np. w Matlabie instrukcją `cond`).

a) Jeśli macierz jest **dobrze uwarunkowana**, to możemy skorzystać z wzoru:

$$\mathbf{K} = [\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}]^{-1} \mathbf{M}^T \underline{\Psi}$$

b) Jeśli macierz jest **źle uwarunkowana** (sprawdzić szczególnie dla długich horyzontów i małych wartości elementów diagonalnych macierzy Λ), to

1. Tworzymy macierze $\mathbf{S}_\Psi = \sqrt{\underline{\Psi}}$, $\mathbf{S}_\Lambda = \sqrt{\underline{\Lambda}}$ (tzn. $\underline{\Psi} = \mathbf{S}_\Psi^T \mathbf{S}_\Psi$, $\underline{\Lambda} = \mathbf{S}_\Lambda^T \mathbf{S}_\Lambda$),

2. Tworzymy macierz

$$\mathbf{A} = \begin{bmatrix} \mathbf{S}_\Psi \mathbf{M} \\ \mathbf{S}_\Lambda \end{bmatrix}_{(N \cdot n_y + N_u \cdot n_u) \times N_u \cdot n_u},$$

3. Dokonujemy rozkładu (wąskiego) $\mathbf{A} = \mathbf{QR}$ (np. w Matlabie: `[Q,R]=qr(A,0)`),

4. Wyznaczamy macierz:

$$[\mathbf{R}^{-1} \mathbf{Q}^T]_{N_u \cdot n_u \times (N \cdot n_y + N_u \cdot n_u)} = [(\mathbf{P}_1)_{N_u \cdot n_u \times N \cdot n_y} (\mathbf{P}_2)_{N_u \cdot n_u \times N_u \cdot n_u}]$$

5. Wyznaczamy macierz $\mathbf{K} = \mathbf{P}_1 \mathbf{S}_\Psi$ (dla $\underline{\Psi} = \mathbf{I}$: $\mathbf{K} = \mathbf{P}_1$);
macierz wzmocnień regulatora $\underline{\mathbf{K}}_1$ to n_u pierwszych wierszy macierzy \mathbf{K} .

Przykład, kolumna Wood-Berry (obiekt MIMO 2x2)

Przypomnijmy model kolumny destylacyjnej metanol-woda, zlinearyzowany w punkcie pracy (**Wood and Berry, 1973**) –
– model obiektu MIMO o 2 wejściach ($n_u=2$) i 2 wyjściach ($n_y=2$) oraz jednym zakłóceniu:

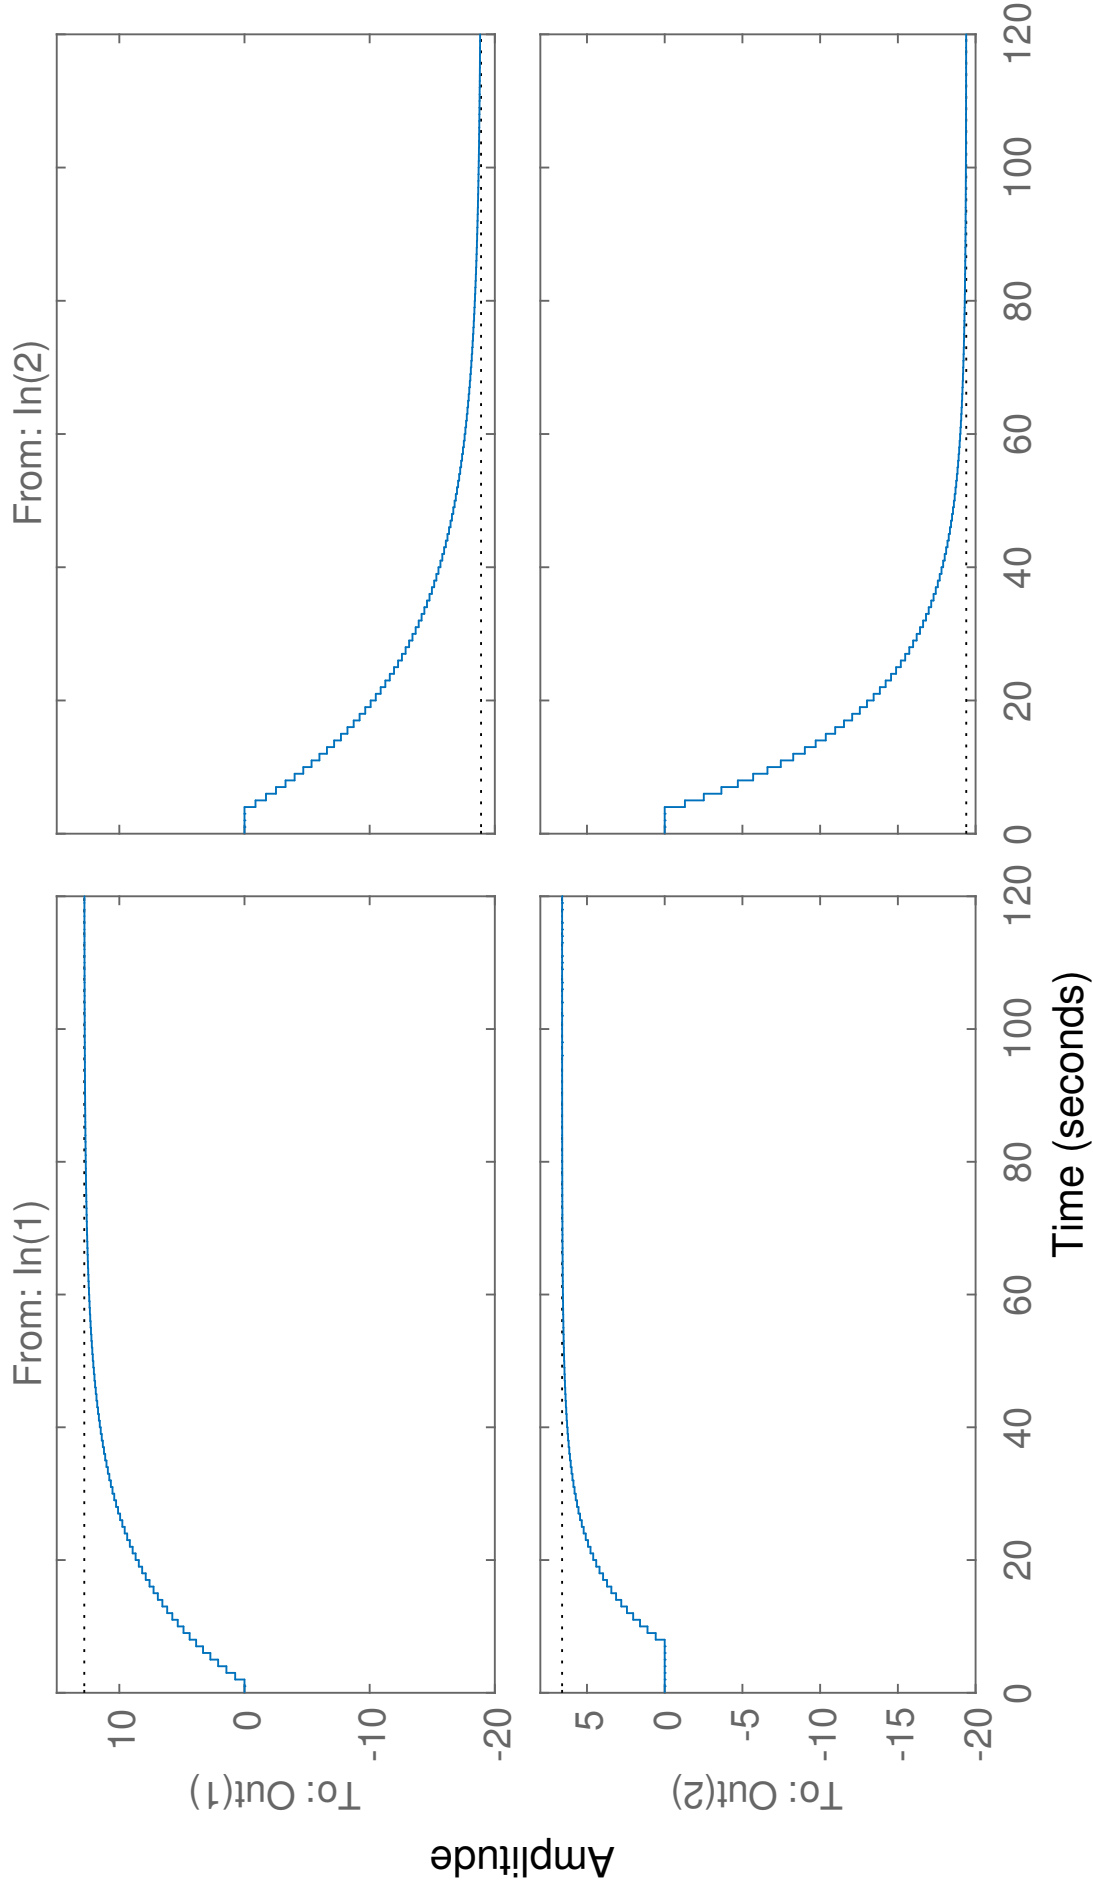
$$\begin{bmatrix} Y_1(s) \\ Y_2(s) \end{bmatrix} = \begin{bmatrix} \frac{12.8e^{-s}}{16.7s+1} & \frac{-18.9e^{-3s}}{21s+1} \\ \frac{6.6e^{-7s}}{10.9s+1} & \frac{-19.4e^{-3s}}{14.4s+1} \end{bmatrix} \begin{bmatrix} U_1(s) \\ U_2(s) \end{bmatrix} + \begin{bmatrix} \frac{3.8e^{-8s}}{14.9s+1} \\ \frac{4.9e^{-3s}}{13.2s+1} \end{bmatrix} F(s)$$

Dyskretyzując model ciągły (Matlab funkcja "c2d") z okresem próbkowania $T_p = 1$ (ze względu na wartości opóźnień) dostajemy:

$$\begin{bmatrix} Y_1(z) \\ Y_2(z) \end{bmatrix} = \begin{bmatrix} \frac{0.744z^{-1}}{z-0.9419} & \frac{-0.8789z^{-3}}{z-0.9535} \\ \frac{0.5786z^{-7}}{z-0.9123} & \frac{-1.302z^{-3}}{z-0.9329} \end{bmatrix} \begin{bmatrix} U_1(z) \\ U_2(z) \end{bmatrix} + \begin{bmatrix} \frac{0.2467z^{-8}}{z-0.9351} \\ \frac{0.3575z^{-3}}{z-0.927} \end{bmatrix} F(z)$$

Przykład, kolumna Wood-Berry (2)

Step Response



Przykład, kolumna Wood-Berry (3)

Projektując regulator DMC (jeden z przykładów na następnym wykładzie) przyjęto $N = 30$, $N_u = 10$; przy $n_y = 2$, $n_u = 2$ daje to wymiar 60×20 macierzy dynamicznej \mathbf{M} , a macierz $\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}$ jest wymiaru 20×20 .

Projektowanie doprowadziło też do przyjęcia wartości $\psi_1 = 1$, $\psi_2 = 1$, $\lambda_1 = 1$, $\lambda_2 = 10$. Dla takich parametrów mamy uwarunkowania:

- $\text{cond}(\mathbf{M}^T \underline{\Psi} \mathbf{M}) = \text{cond}(\mathbf{M}^T \mathbf{M}) = 1.69 \cdot 10^6$,
- $\text{cond}(\mathbf{M}^T \underline{\Psi} \mathbf{M} + \underline{\Lambda}) = \text{cond}(\mathbf{M}^T \mathbf{M} + \underline{\Lambda}) = 5.15 \cdot 10^4$.

Zmieniając współczynniki kary mielibyśmy:

- Dla $\lambda_1 = 1$, $\lambda_2 = 1$: $\text{cond}(\mathbf{M}^T \mathbf{M} + \underline{\Lambda}) = 5.19 \cdot 10^4$,
- Dla $\lambda_1 = 0.1$, $\lambda_2 = 0.1$: $\text{cond}(\mathbf{M}^T \mathbf{M} + \underline{\Lambda}) = 4.07 \cdot 10^5$.

Zmieniając horyzonty predykcji i sterowania (przy $\lambda_1 = 1$, $\lambda_2 = 10$) mielibyśmy:

- Dla $N = 20$, $N_u = 10$: $\text{cond}(\mathbf{M}^T \mathbf{M}) = 4.65 \cdot 10^5$, $\text{cond}(\mathbf{M}^T \mathbf{M} + \underline{\Lambda}) = 1.4 \cdot 10^4$,
- Dla $N = 30$, $N_u = 5$: $\text{cond}(\mathbf{M}^T \mathbf{M}) = 4.73 \cdot 10^5$, $\text{cond}(\mathbf{M}^T \mathbf{M} + \underline{\Lambda}) = 3.1 \cdot 10^4$,
- Dla $N = 10$, $N_u = 3$: $\text{cond}(\mathbf{M}^T \mathbf{M}) = 5.15 \cdot 10^3$, $\text{cond}(\mathbf{M}^T \mathbf{M} + \underline{\Lambda}) = 6.1 \cdot 10^2$.